

Zyrabit SLM: Arquitectura de Nodo Soberano y Guía de Operaciones

Documento Oficial de Arquitectura del Sistema (Versión 5.0)

1. Introducción y Visión General

Zyrabit SLM es un motor de lenguaje pequeño (Small Language Model) soberano diseñado específicamente para entornos corporativos y regulados que requieren soberanía absoluta de datos, aislamiento de red completo (Air-Gap) y procesamiento de lenguaje natural de ultra baja latencia.

A diferencia de las arquitecturas tradicionales basadas en APIs de nube pública, Zyrabit ejecuta inferencia 100% local sobre hardware acelerado, garantizando que ninguna consulta, documento ni métrica de usuario abandone el perímetro de la organización.

2. Principios de Arquitectura Soberana

El sistema se rige bajo tres pilares fundamentales:

A) Privacidad Zero-Trust: Filtrado de información de identificación personal (PII) mediante un sándwich de protección previo a la inferencia.

B) Determinismo Evidence-First: Cada respuesta generada a partir de documentos debe contener citas verificables y referencias exactas de las fuentes indexadas.

C) Eficiencia de Hardware Masiva: Compilación nativa de grafos de PyTorch hacia procesadores Tenstorrent Tensix aprovechando memoria L1/SRAM de alto ancho de banda.

3. Motor de Inferencia Nativo en Tenstorrent Blackhole P150

El núcleo de procesamiento numérico de Zyrabit SLM integra la tarjeta aceleradora Tenstorrent Blackhole P150a a través de la pila vLLM-TT Metalium y el conector zyrabit-tt-bridge.

La traducción de modelos como Qwen 2.5 3B Instruct y DeepSeek R1 1.5B en formato bfloat16 se realiza mediante la siguiente cadena de compilación JIT:

- Captura del grafo dinámico de PyTorch con torch_xla.
- Transformación hacia la representación intermedia dialectal StableHLO.
- Delegación al compilador tt-forge para generación del ejecutable tt-mlir.
- Asignación de tensores sobre la grilla de núcleos Tensix y memoria SRAM/DRAM local.

4. Métricas de Rendimiento Medidas en Hardware Real

En las pruebas operacionales de laboratorio, el sistema demuestra un rendimiento de nivel industrial:

- **Time-To-First-Token (TTFT):** 81.62 ms con Qwen 2.5 3B (superando la meta operacional de menos de 150 ms).
- **Throughput de Generación (TPS):** 21.18 tokens por segundo sostenidos.
- **Estabilidad Matemática:** 0% desbordamientos numéricos (NaN/Inf) en formato bfloat16.

5. Agente Autónomo ReAct V2.0 y Protocolo MCP

Zyrabit SLM incorpora un arnés de razonamiento determinista ReAct (Reasoning + Acting) optimizado para la selección estricta de herramientas sin alucinaciones.

El bucle de ejecución se realiza en modo JSON estructurado validado mediante esquemas Pydantic (ReActAction). El sistema maneja un presupuesto dinámico de contexto de 800 tokens para la identidad del agente y la especificación de herramientas.

6. Integración con Model Context Protocol (MCP)

El servicio MCP expone capacidades extendidas del agente a través de un puente RPC seguro:

- Carga perezosa de herramientas (Lazy Tool Loading) con clasificación de intención de 0 ms.
- Validación de lista blanca de herramientas de ejecución autorizadas (mcp-tools-whitelist.yml).
- Tasa de Éxito en Tareas (Task Success Rate - TSR) superior al 85% en pruebas de selección sintética.

7. Ingesta de Documentos y Búsqueda Híbrida Evidence-First

El servicio de nodo (NodeService) gestiona el ciclo de vida completo de la documentación corporativa desde archivos en formato PDF y texto hacia representaciones vectoriales y léxicas.

El flujo de ingesta comprende las siguientes fases:

1. Parseo y limpieza de texto estructurado eliminando ruido de formato.
2. Fragmentación (Chunking) inteligente por bloques semánticos y encabezados.
3. Indexación híbrida combinando algoritmo léxico BM25 con embeddings vectoriales densos.

8. Aislamiento de Ámbito (Scope Isolation)

Cuando una consulta especifica un `document_id` determinado, el sistema restringe estrictamente la búsqueda al documento seleccionado, evitando contaminar la respuesta con fuentes ajenas o bibliotecas no autorizadas.

9. PII Protection Sandwich y Seguridad Zero-Trust

La privacidad de los datos es la piedra angular del diseño de Zyrabit SLM. Antes de que cualquier tensor o texto sea enviado al motor de inferencia local o al modelo de lenguaje, la solicitud atraviesa el PII Protection Sandwich.

Este componente realiza detección multi-capa mediante expresiones regulares optimizadas y reconocimiento de entidades nombradas (NER) para ofuscar:

- Correos electrónicos corporativos y personales.
- Números de identificación fiscal (RFC, SSN, NIF).
- Direcciones IP internas y credenciales de acceso.

En las auditorías de seguridad y pentesting, el sistema mantiene una tasa de fuga PII (PII Leakage Rate) del 0%.

10. Manual de Operaciones y Mantenimiento del Nodo

Para desplegar y administrar la infraestructura de Zyrabit SLM en entornos de producción o laboratorio, utilice la herramienta CLI `zyra.sh`:

- **Iniciar Stack Completo:** `./zyra.sh up`
- **Ejecutar Benchmark de Rendimiento:** `./zyra.sh benchmark`
- **Auditoría y Pruebas QA:** `./zyra.sh test`

11. Endpoints Principales de la API

- **POST /v1/chat:** Endpoint conversacional para la Web UI y clientes interactivos.
- **POST /v1/query:** Endpoint del nodo soberano para consultas directas basadas en evidencia.
- **POST /v1/sources/import:** Ingesta y fragmentación de nuevos documentos.